

BÀI TẬP LỚN HỌC PHẦN XỬ LÝ DỮ LIỆU LỚN

Lớp: 61.CNTT - GV: Nguyễn Đình Hưng

I. Nội dung bài tập lớn

1. Thiết lập hệ thống xử lý dữ liệu lớn Hadoop (2đ).
2. Thiết lập hệ thống xử lý dữ liệu lớn Spark (1đ).
3. Lập trình xử lý dữ liệu lớn: Sinh viên bốc thăm chọn ngẫu nhiên một trong các bài tập ở Phần II.
 - a. Xây dựng giải thuật MapReduce giải quyết bài toán. (2đ)
 - b. Cài đặt và thực thi chương trình trên Hadoop. (3đ)
 - c. Cài đặt và thực thi chương trình trên Spark. (2đ)

II. Danh mục bài tập lớn

Chú ý: Sinh viên cần chuẩn bị tất cả các bài tập lớn dưới đây, tại buổi thi vấn đáp sinh viên bốc thăm chọn ngẫu nhiên một bài để trình bày.

1. Cho một tập dữ liệu văn bản
 - Đếm số lần xuất hiện của mỗi từ.
 - Đếm tổng số từ.
 - Liệt kê top k từ xuất hiện nhiều nhất.
 - Sử dụng thư viện Matplotlib vẽ biểu đồ cột (bar chart) biểu diễn số lượng của 50 từ xuất hiện nhiều nhất trong tập dữ liệu.
2. Cho tập dữ liệu thời tiết thu thập bởi NCDC (đã tìm hiểu trong quá trình học)
 - Tìm nhiệt độ cao nhất ghi nhận được theo từng năm.
 - Tìm nhiệt độ thấp nhất ghi nhận được theo từng năm.
 - Tính nhiệt độ trung bình theo từng năm.
 - Vẽ biểu đồ biểu diễn nhiệt độ cao nhất, thấp nhất, trung bình theo từng năm.
3. Cho tập dữ liệu lưu các siêu liên kết (hyperlink) của các trang Web (file dữ liệu cung cấp trong trang elearning học phần)
 - Với mỗi trang Web, đếm số liên kết chỉ đến nó.
 - Với mỗi trang Web, liệt kê các Web khác mà nó liên kết đến.
 - Liệt kê top n trang Web được liên kết đến nhiều nhất.
 - Vẽ đồ thị biểu diễn các siêu liên kết trong tập dữ liệu (sử dụng thư viện NetworkX).